

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



TOÁN ỨNG DỤNG VÀ THỐNG KÊ

Đồ án 02 Data Fitting và Phương Pháp OLS

THỰC HIỆN BỞI NHÓM 1

Sinh viên thực hiện:	Trần Nhật Trường - 24120486
	Nguyễn Thanh Nhật - 24120111
	Nguyễn Ngọc Phúc - 24120215
	Trần Lê Đức Việt - 24120245
	Trần Nguyên Tân - 24120438
Giảng viên hướng dẫn:	ThS. Lê Nhựt Nam
	ThS. Võ Nam Thực Đoàn

Thành phố Hồ Chí Minh, 05/2026



Mục lục

Lời nói đầu	1
Lời cam đoan	1
1 Bảng phân công công việc	1
2 Giới thiệu	3
2.1 Mục tiêu của báo cáo	3
2.2 Phạm vi trình bày	3
3 Phần 1: Lý thuyết Data Fitting và minh họa	3
3.1 Bài toán Data Fitting và mô hình hồi quy tuyến tính	3
3.2 Nghiệm OLS và ước lượng phương sai	4
3.3 Ma trận Hat và tính chất	5
3.4 Giả thiết Gauss–Markov và định lý BLUE	7
3.5 Kiểm định thống kê và các chỉ số đánh giá	10
3.6 Minh họa định lý Gauss–Markov bằng Monte Carlo	10
3.7 Phân tích phần dư cho dữ liệu giả lập	11
4 Phần 2: Ứng dụng dữ liệu thực	12
4.1 Nguồn dữ liệu và điều kiện đề bài	12
4.2 Tiền xử lý dữ liệu và DataPipeline	12
4.2.1 Phân tích missing values và outliers	12
4.2.2 Phân tích cơ chế giá trị khuyết thiếu (Missing Values)	12
4.2.3 Phân tích giá trị ngoại lai (Outliers)	13
4.2.4 Quy trình DataPipeline	14
4.3 So sánh mô hình và đánh giá	15
4.4 Ridge Regression và Ridge Trace	15
4.5 k-fold Cross-Validation	16
4.6 Nhận xét	16
4.6.1 OLS cơ bản	16
4.6.2 OLS chọn biến	17
4.6.3 Ridge Regression	17

4.6.4	Lasso Regression	17
4.6.5	Bayesian Linear Regression	17
4.6.6	Tổng hợp	18
4.7	Feature importance và residual plots	19
4.8	Kỹ thuật nâng cao: Bayesian Linear Regression	20
4.9	Lý do chọn Bayesian Linear Regression thay vì Kernel Regression	21
5	Phân tích các hàm chính	21
5.1	Nhóm hàm OLS và kiểm định thống kê	21
5.1.1	<code>ols_fit</code>	21
5.1.2	<code>hat_matrix</code>	22
5.1.3	<code>model_metrics</code>	23
5.1.4	<code>coef_inference</code>	24
5.1.5	<code>vif</code>	24
5.2	Nhóm hàm Ridge và k-fold CV	25
5.2.1	<code>ridge_fit</code>	25
5.2.2	<code>plot_ridge_trace</code>	26
5.2.3	<code>lasso_fit</code>	27
5.2.4	<code>kfold_cv</code>	28
5.3	Nhóm hàm phân tích phần dư	29
5.3.1	<code>residual_plots</code>	29
5.4	Nhóm hàm tiền xử lý dữ liệu	30
5.4.1	<code>DataPipeline.fit</code>	30
5.4.2	<code>DataPipeline.transform</code>	31
5.5	Nhóm hàm Bayesian Linear Regression	32
5.5.1	<code>bayesian_linear_fit</code>	32
5.5.2	<code>bayesian_predict</code>	33
5.5.3	<code>credible_intervals</code>	33
5.6	Nhóm hàm so sánh mô hình	34
5.6.1	<code>train_and_compare</code>	34
6	Kết luận	35



Tài liệu tham khảo	36
Phụ lục A: Bảng số liệu và kết quả bổ sung	37
Phụ lục B: GitHub Repository	38



Lời nói đầu

Lời đầu tiên, tất cả thành viên nhóm gửi lời cảm ơn chân thành đến thầy Lê Nhật Nam và cô Võ Nam Thực Đoàn đã tận tình hướng dẫn, hỗ trợ chúng em trong suốt quá trình thực hiện đồ án này. Trong suốt quá trình làm đồ án này, với sự hướng dẫn tận tình của thầy và cô đã giúp chúng em có cái nhìn tổng quan, sâu sắc và rõ hơn về đồ án ma trận và cơ sở của tính toán khoa học. Chúng em đã học được rất nhiều kiến thức mới, cũng như kỹ năng làm việc nhóm, giải quyết vấn đề và trình bày kết quả một cách hiệu quả.

Chúng em cũng xin gửi sự trân trọng và biết ơn đến các thành viên trong nhóm thực hiện đồ án này đã làm việc chăm chỉ và nỗ lực trong suốt quá trình thực hiện. Sự đóng góp to lớn của mỗi thành viên đã góp phần quan trọng vào thành công của đồ án này. Chúng em đã học được rất nhiều từ nhau, cũng như phát triển kỹ năng làm việc nhóm và giao tiếp hiệu quả.

Trong lúc thực hiện đồ án này không tránh khỏi những khó khăn và thách thức nên sẽ có những sai sót không mong muốn. Chúng em rất mong nhận được sự góp ý, phản hồi từ thầy và cô để có thể hoàn thiện hơn trong quá trình học tập và nghiên cứu sau này.

Lời cam đoan

Trong đồ án lần này, chúng em cam đoan rằng tất cả các nội dung mà chúng em thực hiện đều là kết quả của sự nghiên cứu và làm việc của nhóm chung em.

Chúng em cam đoan rằng không sao chép code hoặc báo cáo từ nhóm khác hay từ Internet mà không trích dẫn nguồn.

Chúng em cam kết khi sử dụng các công cụ AI (ChatGPT, GitHub Copilot, v.v.) để gợi ý thì phải hiểu, trình bày và giải thích lại được nội dung đã được gợi ý.

Chúng em cam đoan rằng tất cả các thành viên trong nhóm đều đã đóng góp công sức và kiến thức của mình vào đồ án này một cách công bằng và trung thực. Chúng em cam đoan rằng nếu có bất kỳ vi phạm nào liên quan đến đạo đức học thuật hoặc gian lận, chúng em sẽ chịu trách nhiệm hoàn toàn và chấp nhận mọi hình phạt theo quy định của nhà trường.

1 Bảng phân công công việc



Tên	Nội dung	Phần trăm đánh giá
Nguyễn Thanh Nhật	• Trình bày và chứng minh lý thuyết OLS • Cài đặt <code>ols_fit</code> và <code>hat_matrix</code> • Viết unit test cho OLS và hat matrix • Minh họa định lý Gauss–Markov bằng Monte Carlo • Bổ sung Markdown phần công thức cốt lõi trong notebook	100%
Trần Lê Đức Việt	• Cài đặt <code>model_metrics</code>, <code>coef_inference</code>, <code>vif</code> • Viết unit test cho các hàm kiểm định thống kê • Bổ sung Markdown giải thích F-test, t-test, RSS, R^2	100%
Trần Nhật Trường	• Thực hiện EDA dữ liệu Air Quality • Phân tích cơ chế missing values và outliers • Thiết kế <code>DataPipeline</code> (fit/transform, imputation, encoding, Z-score) • Bổ sung Markdown mô tả EDA và pipeline trong notebook	100%
Trần Nguyên Tân	• Cài đặt Ridge Regression và k-fold CV • Vẽ Ridge Trace và chọn lambda tối ưu • Tích hợp so sánh mô hình trong <code>model_comparison.py</code> • Triển khai Bayesian Linear Regression • Viết nhận xét kết quả so sánh mô hình	100%
Nguyễn Ngọc Phúc	• Cài đặt <code>residual_plots</code> và unit test • Vẽ và nhận xét 4 biểu đồ phần dư cho Phần 1 • Vẽ Feature Importance cho OLS và residual plots Phần 2 • Tổng hợp nội dung báo cáo và chỉnh <code>README.md</code>	100%

Bảng 1: Bảng đánh giá chi tiết

2 Giới thiệu

2.1 Mục tiêu của báo cáo

- Trình bày nền tảng lý thuyết của bài toán data fitting và phương pháp OLS, bao gồm nghiệm OLS, ma trận Hat và các giả thiết Gauss–Markov.
- Cài đặt các thuật toán chính (OLS, Ridge, k-fold CV) và các kiểm định thống kê (F-test, t-test, khoảng tin cậy), đối chiếu với NumPy/sklearn để xác thực.
- Xây dựng pipeline tiền xử lý dữ liệu thực, đảm bảo đúng nguyên tắc fit/transform và tránh data leakage.
- So sánh hiệu suất nhiều mô hình trên tập test, phân tích phần dư và giải thích feature importance.
- Rút ra kết luận về mức độ phù hợp của mô hình tuyến tính trên dữ liệu Air Quality và định hướng cải thiện.

2.2 Phạm vi trình bày

- Phần 1: lý thuyết OLS, minh họa bằng dữ liệu giả lập, kiểm định thống kê và phân tích phần dư.
- Phần 2: dữ liệu Air Quality, EDA, tiền xử lý, so sánh mô hình và đánh giá trên tập test.
- Kỹ thuật nâng cao: Bayesian Linear Regression để bổ sung điểm bonus.

3 Phần 1: Lý thuyết Data Fitting và minh họa

3.1 Bài toán Data Fitting và mô hình hồi quy tuyến tính

Bài toán data fitting tìm hàm $f: \mathbb{R}^p \rightarrow \mathbb{R}$ sao cho xấp xỉ tốt nhất mối quan hệ giữa x_i và y_i theo tiêu chí đã chọn. Trong hồi quy tuyến tính, ta giả thiết:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \epsilon_i = x_i^T \beta + \epsilon_i \quad (1)$$

Viết dưới dạng ma trận với $X \in \mathbb{R}^{n \times (p+1)}$ (cột đầu toàn 1):

$$y = X\beta + \epsilon \quad (2)$$

3.2 Nghiệm OLS và ước lượng phương sai

Phương pháp Bình phương tối thiểu thông thường (OLS) xác định vector tham số β bằng cách tối thiểu hóa tổng bình phương các sai số giữa giá trị thực tế và giá trị dự báo. Đại lượng này được gọi là **Tổng bình phương phần dư** (Residual Sum of Squares – RSS):

$$RSS(\beta) = \|y - X\beta\|_2^2 = (y - X\beta)^T(y - X\beta) \quad (3)$$

Định lý. Nếu ma trận $X^T X$ là ma trận khả nghịch, nghiệm OLS duy nhất được xác định bởi công thức:

$$\hat{\beta}_{OLS} = (X^T X)^{-1} X^T y \quad (4)$$

Chứng minh chi tiết:

Bước 1: Khai triển hàm RSS. Ta thực hiện nhân phân phối các ma trận:

$$RSS(\beta) = y^T y - y^T X\beta - (X\beta)^T y + (X\beta)^T (X\beta)$$

Sử dụng tính chất chuyển vị của ma trận tích $(AB)^T = B^T A^T$, ta có $(X\beta)^T = \beta^T X^T$. Do kết quả của $y^T X\beta$ là một số vô hướng (scalar) — kích thước 1×1 , chuyển vị của một số vô hướng bằng chính nó:

$$(y^T X\beta)^T = \beta^T X^T y$$

Nên ta có thể gộp hai số hạng ở giữa lại với nhau:

$$RSS(\beta) = y^T y - 2\beta^T X^T y + \beta^T X^T X\beta \quad (5)$$

Bước 2: Tính đạo hàm bậc một (gradient) theo β . Để tìm cực tiểu, ta lấy đạo hàm riêng của $RSS(\beta)$ theo vector β , sử dụng các quy tắc vi phân ma trận:

$$\frac{\partial(a^T x)}{\partial x} = a, \quad \frac{\partial(x^T A x)}{\partial x} = (A + A^T)x$$

Áp dụng cho từng số hạng trong (5):

- Đạo hàm của $y^T y$ (hằng số đối với β) là $\mathbf{0}$.
- Đạo hàm của $-2\beta^T X^T y$ theo β là $-2X^T y$.
- Đạo hàm của $\beta^T (X^T X)\beta$ theo β là $2X^T X\beta$ (vì $X^T X$ là ma trận đối xứng).

Gộp lại, ta được vector Gradient:

$$\nabla_{\beta} RSS = -2X^T y + 2X^T X \beta = -2X^T (y - X \beta) \quad (6)$$

Bước 3: Giải phương trình Gradient bằng 0 (điều kiện cần). Đặt $\nabla_{\beta} RSS = \mathbf{0}$, ta có:

$$\begin{aligned} -2X^T (y - X \beta) &= \mathbf{0} \\ \iff X^T X \beta &= X^T y \end{aligned} \quad (7)$$

Đây là **Hệ phương trình chuẩn** (Normal Equations).

Bước 4: Điều kiện đủ để là điểm cực tiểu. Tính ma trận đạo hàm bậc 2 (Hessian) của $RSS(\beta)$:

$$\nabla_{\beta}^2 RSS = \frac{\partial}{\partial \beta} (2X^T X \beta - 2X^T y) = 2X^T X$$

Với giả thiết GM2 (Không hoàn hảo đa cộng tuyến), $\text{rank}(X) = p + 1$, ma trận $X^T X$ là ma trận xác định dương (positive definite). Do đó, hàm RSS là hàm lồi chặt (strictly convex) và điểm dừng tìm được là điểm cực tiểu toàn cục duy nhất.

Bước 5: Nghiệm OLS. Vì $X^T X$ xác định dương nên nó có khả năng nghịch đảo. Nhân cả hai vế của hệ phương trình chuẩn (7) với $(X^T X)^{-1}$, ta thu được:

$$\hat{\beta}_{OLS} = (X^T X)^{-1} X^T y \quad (8)$$

Ước lượng phương sai nhiễu. Vì phương sai của nhiễu σ^2 thường không được biết trước trong thực tế, ta sử dụng một ước lượng không chệch dựa trên phần dư của mô hình:

$$\hat{\sigma}^2 = \frac{RSS}{n - p - 1} = \frac{\|y - X \hat{\beta}\|^2}{n - p - 1} \quad (9)$$

3.3 Ma trận Hat và tính chất

Định nghĩa. Ma trận chiếu (projection matrix), hay còn gọi là hat matrix, được ký hiệu là H , dùng để ánh xạ từ vector quan sát thực tế y đến vector giá trị dự báo $\hat{y}$:

$$H = X(X^T X)^{-1} X^T \in \mathbb{R}^{n \times n} \quad (10)$$

Khi đó giá trị dự báo và phần dư được biểu diễn:

$$\hat{y} = Hy, \quad \hat{\epsilon} = y - \hat{y} = (I - H)y$$

Về mặt hình học, $\hat{y}$ là hình chiếu vuông góc của y lên không gian cột $\text{Col}(X)$ của ma trận thiết kế X .

Các tính chất quan trọng và chứng minh:

(i) Tính đối xứng: $H^T = H$.

Chứng minh. Sử dụng tính chất $(ABC)^T = C^T B^T A^T$ và $(A^{-1})^T = (A^T)^{-1}$:

$$\begin{aligned} H^T &= (X(X^T X)^{-1} X^T)^T \\ &= (X^T)^T \cdot ((X^T X)^{-1})^T \cdot X^T \\ &= X \cdot ((X^T X)^T)^{-1} \cdot X^T \\ &= X \cdot (X^T X)^{-1} \cdot X^T = H \end{aligned}$$

(ii) Tính lũy đẳng (Idempotent): $H^2 = H$.

Chứng minh.

$$\begin{aligned} H^2 &= H \cdot H \\ &= X(X^T X)^{-1} X^T \cdot X(X^T X)^{-1} X^T \\ &= X(X^T X)^{-1} \underbrace{(X^T X)(X^T X)^{-1}}_{=I_{p+1}} X^T \\ &= X(X^T X)^{-1} X^T = H \end{aligned}$$

Ý nghĩa: Việc chiếu một vector hai lần lên cùng một không gian con không làm thay đổi kết quả sau lần chiếu đầu tiên.

(iii) Giá trị riêng của H chỉ là 0 hoặc 1.

Chứng minh. Giả sử λ là giá trị riêng của H với vector riêng $v \neq 0$:

$$Hv = \lambda v$$

Nhân cả hai về với H (bên trái):

$$H^2v = H(\lambda v) = \lambda Hv = \lambda^2v$$

Mặt khác, do $H^2 = H$ (tính lũy đẳng):

$$H^2v = Hv = \lambda v$$

Suy ra $\lambda^2v = \lambda v$, tức $(\lambda^2 - \lambda)v = 0$. Vì $v \neq 0$, ta được:

$$\lambda^2 - \lambda = 0 \implies \lambda(\lambda - 1) = 0 \implies \lambda \in \{0, 1\}$$

(iv) $\text{rank}(H) = p + 1$.

Chứng minh. Do $\text{rank}(X) = p + 1$ (giả thiết GM2) và $(X^T X)^{-1}$ là ma trận khả nghịch kích thước $(p + 1) \times (p + 1)$, ta có:

$$\text{rank}(H) = \text{rank}(X(X^T X)^{-1}X^T) = \text{rank}(X) = p + 1$$

Ngoài ra, $\text{trace}(H) = \text{trace}(X(X^T X)^{-1}X^T) = \text{trace}((X^T X)^{-1}X^T X) = \text{trace}(I_{p+1}) = p + 1$. Vì giá trị riêng chỉ là 0 hoặc 1 và tổng giá trị riêng bằng $\text{trace}(H)$, nên có đúng $p + 1$ giá trị riêng bằng 1, phù hợp với $\text{rank}(H) = p + 1$.

3.4 Giả thiết Gauss–Markov và định lý BLUE

Các giả thiết Gauss–Markov (GM1 – GM5):

- **GM1. Tuyến tính** (Linear in parameters): $y = X\beta + \epsilon$. Mô hình thực tế phải tuyến tính đối với các tham số β , dù có thể phi tuyến đối với các biến độc lập.
- **GM2. Không hoàn hảo đa cộng tuyến:** $\text{rank}(X) = p + 1$. Các cột của X phải độc lập tuyến tính, đảm bảo $X^T X$ khả nghịch.
- **GM3. Ngoại sinh (Strict Exogeneity):** $\mathbb{E}[\epsilon | X] = \mathbf{0}$, tức sai số ngẫu nhiên có kỳ vọng bằng 0 có điều kiện trên X .
- **GM4. Đồng phương sai và không tự tương quan:** $\text{Var}(\epsilon | X) = \sigma^2 I_n$. Phương sai phần dư là hằng số, và không có tương quan giữa phần dư của các quan sát khác nhau.

- **GM5. Phần dư chuẩn:** $\epsilon \mid X \sim \mathcal{N}(\mathbf{0}, \sigma^2 I_n)$. Giả thiết này không bắt buộc cho OLS nhưng cần thiết cho kiểm định thống kê (t-test, F-test).

Định lý Gauss–Markov. Dưới các giả thiết GM1–GM4, ước lượng OLS $\hat{\beta}_{OLS}$ là **Ước lượng tuyến tính không chệch tốt nhất** (Best Linear Unbiased Estimator - BLUE):

- **(i) Tính không chệch:** $\mathbb{E}[\hat{\beta}_{OLS}] = \beta$.
- **(ii) Tính tốt nhất** (hiệu quả): Trong số tất cả các ước lượng tuyến tính và không chệch, OLS có phương sai nhỏ nhất.

Ma trận hiệp phương sai của ước lượng OLS:

$$\text{Var}(\hat{\beta}_{OLS} \mid X) = \sigma^2 (X^T X)^{-1} \quad (11)$$

Chứng minh tính không chệch.

Thay $y = X\beta + \epsilon$ vào công thức nghiệm OLS:

$$\begin{aligned} \hat{\beta}_{OLS} &= (X^T X)^{-1} X^T y \\ &= (X^T X)^{-1} X^T (X\beta + \epsilon) \\ &= \underbrace{(X^T X)^{-1} X^T X}_{=I_{p+1}} \beta + (X^T X)^{-1} X^T \epsilon \\ &= \beta + (X^T X)^{-1} X^T \epsilon \end{aligned}$$

Lấy kỳ vọng có điều kiện trên X và sử dụng GM3 ($\mathbb{E}[\epsilon \mid X] = \mathbf{0}$):

$$\mathbb{E}[\hat{\beta}_{OLS} \mid X] = \beta + (X^T X)^{-1} X^T \underbrace{\mathbb{E}[\epsilon \mid X]}_{=0} = \beta$$

Chứng minh công thức phương sai.

Từ kết quả trên, $\hat{\beta}_{OLS} - \beta = (X^T X)^{-1} X^T \epsilon$. Đặt $C = (X^T X)^{-1} X^T$:

$$\begin{aligned}\text{Var}(\hat{\beta}_{OLS} | X) &= \mathbb{E}[(\hat{\beta}_{OLS} - \beta)(\hat{\beta}_{OLS} - \beta)^T | X] \\ &= C \cdot \mathbb{E}[\epsilon \epsilon^T | X] \cdot C^T \\ &= C \cdot \sigma^2 I_n \cdot C^T \quad (\text{theo GM4}) \\ &= \sigma^2 \cdot (X^T X)^{-1} X^T \cdot X (X^T X)^{-1} \\ &= \sigma^2 (X^T X)^{-1}\end{aligned}$$

Chứng minh tính tốt nhất (BLUE).

Giả sử $\tilde{\beta} = Ay$ là một ước lượng tuyến tính không chệch khác của β , trong đó A là một ma trận $(p+1) \times n$ xác định (không phụ thuộc vào y).

Để $\tilde{\beta}$ không chệch, cần:

$$\mathbb{E}[\tilde{\beta}] = \mathbb{E}[A(X\beta + \epsilon)] = AX\beta + A\mathbb{E}[\epsilon] = AX\beta = \beta$$

với mọi β , suy ra $AX = I_{p+1}$.

Đặt $D = A - (X^T X)^{-1} X^T$, khi đó:

$$DX = AX - (X^T X)^{-1} X^T X = I_{p+1} - I_{p+1} = O$$

Tính phương sai:

$$\begin{aligned}\text{Var}(\tilde{\beta}) &= A \cdot \text{Var}(\epsilon) \cdot A^T = \sigma^2 AA^T \\ &= \sigma^2 (D + (X^T X)^{-1} X^T) (D + (X^T X)^{-1} X^T)^T \\ &= \sigma^2 (DD^T + DX(X^T X)^{-1} + (X^T X)^{-1} X^T D^T + (X^T X)^{-1})\end{aligned}$$

Do $DX = O$, nên $DX(X^T X)^{-1} = O$ và $(X^T X)^{-1} X^T D^T = (DX(X^T X)^{-1})^T = O^T = O$. Vậy:

$$\text{Var}(\tilde{\beta}) = \sigma^2 (X^T X)^{-1} + \sigma^2 DD^T = \text{Var}(\hat{\beta}_{OLS}) + \sigma^2 DD^T$$

Vì DD^T là ma trận nửa xác định dương (tức $\sigma^2 DD^T \geq 0$), ta suy ra:

$$\text{Var}(\tilde{\beta}) \geq \text{Var}(\hat{\beta}_{OLS})$$

trong đó bất đẳng thức hiểu theo nghĩa hiệu $\text{Var}(\tilde{\beta}) - \text{Var}(\hat{\beta}_{OLS})$ là ma trận nửa xác định dương. Đẳng thức xảy ra khi và chỉ khi $D = O$, tức $A = (X^T X)^{-1} X^T$, hay $\tilde{\beta} = \hat{\beta}_{OLS}$.

Do đó, trong lớp các ước lượng tuyến tính không chệch, ước lượng OLS có phương sai nhỏ nhất.

3.5 Kiểm định thống kê và các chỉ số đánh giá

Các chỉ số đánh giá và kiểm định quan trọng:

- RSS , TSS , R^2 và $\bar{R}^2$ để đánh giá mức độ giải thích của mô hình.
- **F-test** kiểm định ý nghĩa toàn mô hình:

$$F = \frac{(TSS - RSS)/p}{RSS/(n - p - 1)} \sim F_{p, n-p-1} \quad (12)$$

- **t-test** kiểm định ý nghĩa từng hệ số:

$$t_j = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{[(X^T X)^{-1}]_{jj}}} \sim t_{n-p-1} \quad (13)$$

- **VIF** để phát hiện đa cộng tuyến:

$$VIF_j = \frac{1}{1 - R_j^2} \quad (14)$$

3.6 Minh họa định lý Gauss–Markov bằng Monte Carlo


Nhóm thực hiện mô phỏng Monte Carlo với dữ liệu giả lập để kiểm chứng $\mathbb{E}[\hat{\beta}] = \beta$ và OLS có phương sai nhỏ nhất so với một ước lượng tuyến tính không chệch khác. Mỗi vòng lặp sinh nhiều, fit OLS và một ước lượng thay thế (sử dụng tập con), sau đó so sánh kỳ vọng và phương sai thực nghiệm của hai ước lượng.

```
--- KIEM CHUNG TINH KHONG CHECH (E[beta] = beta) ---  
Beta thuc te      : [ 2.5  1.2 -0.8  3. ]  
Ky vong OLS       : [ 2.50101355  1.20260482 -0.80261208  2.9944932 ]  
Ky vong uoc luong khac : [ 2.50090563  1.19819289 -0.79960851  2.99447599 ]  
  
--- KIEM CHUNG PHUONG SAI NHO NHAT (BLUE) ---  
Phuong sai ly thuyet OLS : [0.02361008 0.03404381 0.02417741 0.01894478]  
Phuong sai thuc te OLS   : [0.02571405 0.0372188 0.0236411 0.02012301]  
Phuong sai uoc luong khac : [0.03658635 0.05546988 0.03752435 0.02673934]
```

Hình 1: Minh họa Gauss–Markov bằng mô phỏng Monte Carlo.

3.7 Phân tích phần dư cho dữ liệu giả lập

Bốn biểu đồ chẩn đoán được sử dụng: Residuals vs Fitted, Q–Q Plot, Scale–Location, Cook’s Distance. Kết quả cho thấy phần dư phân tán quanh 0, Q–Q gần tuyến tính, Scale–Location tương đối phẳng và không có điểm ảnh hưởng quá lớn, phù hợp với giả định OLS.



Hình 2: Residual plots cho dữ liệu giả lập.

4 Phần 2: Ứng dụng dữ liệu thực

4.1 Nguồn dữ liệu và điều kiện đề bài

Bộ dữ liệu sử dụng là **Air Quality** (dữ liệu cảm biến chất lượng không khí theo thời gian). Dữ liệu bao gồm các biến cảm biến như $CO(GT)$, $PT08.S1(CO)$, $PT08.S2(NMHC)$, $NOx(GT)$, T , RH , AH cùng cột thời gian $Date/Time$. Target được chọn là $C6H6(GT)$ (nồng độ benzene), là biến liên tục. Sau khi loại các dòng thiếu target, dữ liệu còn hơn 9000 quan sát và số biến đặc trưng lớn hơn 3.

Nguồn dữ liệu: <https://archive.ics.uci.edu/dataset/360/air+quality>.

Đối chiếu với yêu cầu đề bài:

- Dữ liệu thực: thu thập từ cảm biến môi trường.
- Có missing values: nhiều cột có tỉ lệ missing vượt 5%.
- Target liên tục: $C6H6(GT)$.
- Kích thước: $n \geq 200$, $p \geq 3$.


Như vậy bộ dữ liệu thỏa mãn đầy đủ điều kiện của đề bài.

4.2 Tiền xử lý dữ liệu và DataPipeline

4.2.1 Phân tích missing values và outliers

4.2.2 Phân tích cơ chế giá trị khuyết thiếu (Missing Values)

Dữ liệu từ các cảm biến đo lường thường xuyên bị thiếu sót. Qua phân tích, cơ chế missing value của bộ dữ liệu này được xác định chủ yếu là khuyết thiếu ngẫu nhiên (Missing At Random - MAR).




Hình 3: Tỷ lệ khuyết thiếu của các cảm biến trong bộ dữ liệu Air Quality.

Biện luận: Sự cố của một cảm biến (ví dụ: cảm biến CO) thường không phụ thuộc vào chính nồng độ khí CO lúc đó, mà phụ thuộc vào các yếu tố ngoại cảnh khác như nhiệt độ hoặc độ ẩm quá cao/quá thấp khiến cảm biến bị lỗi tạm thời.

Chiến lược xử lý: Vì lý do trên, phương pháp xóa dòng (Listwise Deletion) bị loại bỏ vì sẽ làm mất mát một lượng lớn thông tin quan trọng. Thay vào đó, nhóm quyết định áp dụng chiến lược điền khuyết (Imputation) để bảo toàn dữ liệu. Các cột có tỉ lệ missing quá cao ($> 50\%$) mới bị loại bỏ hoàn toàn do độ tin cậy không còn đảm bảo.

4.2.3 Phân tích giá trị ngoại lai (Outliers)

Biểu đồ Boxplot và phân phối cho thấy dữ liệu cảm biến chứa rất nhiều giá trị ngoại lai (những thời điểm nồng độ khí tăng vọt bất thường).



Hình 4: So sánh phân phối dữ liệu trước và sau khi áp dụng IQR Winsorization.

Chiến lược xử lý: Nhóm quyết định không xóa các điểm ngoại lai này (vì sẽ mâu thuẫn với nỗ lực điền khuyết bảo toàn dữ liệu ở trên), mà sử dụng phương pháp cắt ngọn (Winsorization). Ngoài ra, việc tồn tại nhiều outliers cũng là cơ sở để nhóm quyết định dùng trung vị thay vì trung bình trong quá trình điền khuyết các biến số thực, do trung vị mang tính bền vững (robust) hơn trước outlier.

Công thức IQR capping:

$$IQR = Q_3 - Q_1$$

$$\text{Lower} = Q_1 - 1.5 \times IQR$$

$$\text{Upper} = Q_3 + 1.5 \times IQR$$

4.2.4 Quy trình DataPipeline

Pipeline gồm 6 bước, thực hiện theo đúng thứ tự và chỉ **fit trên train**:

1. **Trích xuất đặc trưng (Feature engineering):** trích xuất Month, DayOfWeek, Hour từ Date/Time, sau đó loại bỏ cột gốc.
2. **Loại cột thiếu quá nhiều:** các cột có tỉ lệ missing vượt ngưỡng 50% được loại bỏ.
3. **Điền khuyết (Imputation):** biến số thực điền bằng median (robust với outliers), biến phân loại điền bằng mode. Với biến thời gian, dùng median để đảm bảo giá trị hợp lệ.

4. **Xử lý ngoại lai (Outlier handling):** áp dụng IQR capping cho các biến số (không áp dụng cho biến thời gian).
5. **Mã hóa One-hot:** mã hóa các biến phân loại, đồng thời reindex để test có cùng cấu trúc cột như train.
6. **Chuẩn hóa Z-score:** $x_{std} = (x - \mu)/\sigma$ để đưa các biến về cùng thang đo.

Nguyên tắc chống data leakage:

- Tất cả tham số (median/mode, IQR bounds, danh sách cột, mean/std) chỉ học từ train.
- Test chỉ được transform bằng tham số đã học.

4.3 So sánh mô hình và đánh giá

4.4 Ridge Regression và Ridge Trace

OLS tìm nghiệm bằng cách tối thiểu hóa tổng bình phương phần dư:

$$\hat{\beta}_{OLS} = (X^T X)^{-1} X^T y \quad (15)$$

Khi các cột trong X tương quan mạnh, $X^T X$ có thể gần suy biến khiến hệ số OLS kém ổn định. Ridge Regression thêm thành phần phạt L_2 :

$$\hat{\beta}_{ridge} = \arg \min_{\beta} \{ \|y - X\beta\|_2^2 + \lambda \|\beta\|_2^2 \} \quad (16)$$

Nghiệm đóng của Ridge là:

$$\hat{\beta}_{ridge} = (X^T X + \lambda I')^{-1} X^T y \quad (17)$$

trong đó I' là ma trận đơn vị nhưng phần tử $I'_{00} = 0$ để không regularize hệ số chặn.

Ridge Trace là biểu đồ thể hiện sự thay đổi của từng hệ số theo $\log_{10}(\lambda)$. Khi λ tăng, các hệ số bị co dần về 0; hệ số ổn định qua nhiều giá trị λ thường có vai trò quan trọng hơn. Ridge Trace giúp quan sát trực quan mức độ co hệ số và hỗ trợ lựa chọn vùng λ phù hợp, tránh underfit.

4.5 k-fold Cross-Validation

k-fold CV chia tập train thành k phần gần bằng nhau. Mỗi lần dùng $k - 1$ phần để huấn luyện và 1 phần để kiểm tra, lặp k lần. Điểm CV-MSE được tính:

$$CV_{(k)} = \frac{1}{k} \sum_{i=1}^k MSE_i \quad (18)$$

Trong dự án, k-fold CV được dùng để chọn λ tối ưu cho Ridge. Mỗi giá trị λ được đánh giá bằng CV-MSE, và λ có CV-MSE nhỏ nhất được chọn.

Kết quả được lấy từ script `part2/model_comparison.py` với seed 42, chia train/test 80/20 và chọn lambda Ridge bằng 5-fold CV trên tập train. Các chỉ số đánh giá:

$$MAE = \frac{1}{n} \sum_i |y_i - \hat{y}_i|$$
$$RMSE = \sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2}$$
$$R^2 = 1 - \frac{RSS}{TSS}$$

Model	MAE	RMSE	R^2
OLS	0.889981	1.446089	0.963608
OLS (Variable Selection)	1.428491	2.072625	0.925242
Ridge ($\lambda = 0.1$)	0.889957	1.446081	0.963608
Lasso ($\lambda = 0.0001$)	0.889858	1.446016	0.963611
Bayesian Linear Regression	0.889976	1.446087	0.963608

Bảng 2: So sánh hiệu suất 5 mô hình trên tập test Air Quality (seed=42, train/test 80/20, k=5 CV).

4.6 Nhận xét

4.6.1 OLS cơ bản

OLS cơ bản sử dụng toàn bộ biến sau tiền xử lý. Mô hình đạt $MAE = 0.889981$, $RMSE = 1.446089$ và $R^2 = 0.963608$ trên tập test. Điều này cho thấy quan hệ tuyến tính giữa các tín hiệu cảm biến và nồng độ benzene là rất mạnh. Tuy nhiên, OLS nhạy với đa cộng tuyến nên hệ số có thể kém ổn định khi các cảm biến tương quan cao.

4.6.2 OLS chọn biến

OLS chọn biến loại bỏ các biến có $VIF > 10$ hoặc $p\text{-value} > 0.05$. Trong lần chạy này, các biến PT08.S2(NMHC) và T bị loại do VIF cao. Hiệu suất giảm đáng kể ($MAE = 1.428491$, $RMSE = 2.072625$, $R^2 = 0.925242$), cho thấy việc loại biến làm mất một phần thông tin dự báo quan trọng, đặc biệt khi các biến đa cộng tuyến vẫn mang tín hiệu mạnh với target.

Bước	Biến bị loại	Lý do	Giá trị
1	PT08.S2(NMHC)	VIF	31.742536
2	T	VIF	14.549521

Bảng 3: Các biến bị loại trong OLS chọn biến.

4.6.3 Ridge Regression

Ridge được chọn với $\lambda = 0.1$ bằng k-fold CV. Mô hình đạt $MAE = 0.889957$ và $RMSE = 1.446081$ (tốt nhất nhưng chỉ nhỉnh hơn OLS rất nhỏ). Ridge giữ lại toàn bộ biến và co nhỏ hệ số, nên phù hợp khi muốn giảm variance mà không loại bỏ tín hiệu.

4.6.4 Lasso Regression

Lasso Regression được cài đặt bằng Coordinate Descent. Tương tự Ridge, λ tối ưu được chọn bằng k-fold CV ($k = 5$) trên tập train. Điểm khác biệt cốt lõi so với Ridge là Lasso dùng chuẩn L_1 :

$$\hat{\beta}_{lasso} = \arg \min_{\beta} \{ \|y - X\beta\|_2^2 + \lambda \|\beta\|_1 \} \quad (19)$$


Do chuẩn L_1 không có nghiệm đóng, thuật toán Coordinate Descent cập nhật từng hệ số bằng toán tử soft-threshold $S(z, \gamma) = \text{sign}(z) \cdot \max(|z| - \gamma, 0)$. Lasso có xu hướng đưa các hệ số kém quan trọng về đúng 0, tạo ra mô hình thưa (sparse) – khác với Ridge chỉ co nhỏ hệ số. Trên dữ liệu Air Quality, Lasso đạt kết quả tối ưu nhất trên tập test với $MAE = 0.889858$ và $RMSE = 1.446016$ do loại bỏ thành công các biến ít đóng góp.

4.6.5 Bayesian Linear Regression


Bayesian Linear Regression đạt $MAE = 0.889976$, $RMSE = 1.446087$ và $R^2 = 0.963608$. Kết quả gần OLS/Ridge vì prior tương đối yếu sau khi chuẩn hóa dữ liệu. Ưu điểm là mô hình cung cấp posterior covariance, giúp diễn giải độ bất định của hệ số.

4.6.6 Tổng hợp

OLS, Ridge, Lasso và Bayesian Linear Regression có hiệu suất gần như tương đương, phản ánh dữ liệu phù hợp với mô hình tuyến tính. OLS chọn biến giúp mô hình gọn hơn nhưng giảm độ chính xác đáng kể. Ridge và Lasso đều xử lý đa cộng tuyến theo hướng khác nhau: Ridge co nhỏ tất cả hệ số, còn Lasso ưu tiên tạo mô hình thưa bằng cách đưa các hệ số kém quan trọng về 0. Ridge là lựa chọn cân bằng nếu ưu tiên tính ổn định của hệ số.




Hình 5: Biểu đồ so sánh hiệu năng các mô hình (MAE, RMSE, R-squared).



Hình 6: Phân tán giá trị Thực tế vs Dự báo của 5 mô hình hồi quy.


4.7 Feature importance và residual plots

Hệ số hồi quy sau chuẩn hóa được dùng để biểu diễn độ quan trọng của đặc trưng. Các biến có |hệ số| lớn nhất là nhóm ảnh hưởng mạnh nhất tới $C_6H_6(GT)$; trong dữ liệu này, các cảm biến liên quan đến hydrocarbon như $PT08.S2(NMHC)$ và $CO(GT)$ thường có tác động mạnh, bên cạnh các biến điều kiện môi trường.



Hình 7: Feature importance theo hệ số OLS đã chuẩn hóa.

Đồng thời, 4 biểu đồ phần dư (Residuals vs Fitted, Q-Q, Scale-Location, Cook's Distance) được dùng để kiểm tra giả thiết tuyến tính, chuẩn và đồng phương sai. Kết quả cho thấy phần dư phân tán quanh 0 và không có điểm ảnh hưởng quá lớn, phù hợp với giả định OLS.



Hình 8: Residual plots cho dữ liệu Air Quality.

4.8 Kỹ thuật nâng cao: Bayesian Linear Regression

Bayesian Linear Regression được dùng để lấy điểm bonus. Mô hình giữ cấu trúc tuyến tính:

$$y = X\beta + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2 I)$$

$$\beta \sim \mathcal{N}(m_0, S_0)$$

Sau khi quan sát dữ liệu, posterior của hệ số là:

$$S_n = \left(S_0^{-1} + \frac{1}{\sigma^2} X^T X \right)^{-1}$$
$$m_n = S_n \left(S_0^{-1} m_0 + \frac{1}{\sigma^2} X^T y \right)$$

Trong triển khai hiện tại, prior mean là vector 0, prior variance = 100 cho các hệ số và intercept
prior variance = 10^{12} để gần như không regularize intercept. Khi prior yếu, posterior mean gần

OLS; khi prior mạnh, hệ số bị shrink. Lựa chọn Bayesian Linear Regression phù hợp với đề bài vì vẫn giữ cấu trúc tuyến tính, dễ giải thích hệ số và không cần ma trận Gram lớn như Kernel Regression.

4.9 Lý do chọn Bayesian Linear Regression thay vì Kernel Regression

Kernel Regression có khả năng mô hình hóa quan hệ phi tuyến nhưng đòi hỏi xây dựng và nghịch đảo ma trận Gram kích thước $n \times n$, không phù hợp khi n lớn như bộ Air Quality. Trong khi đó, Bayesian Linear Regression chỉ cần nghịch đảo ma trận kích thước $(p+1) \times (p+1)$ nên phù hợp với helper ma trận tự cài. Ngoài ra, dữ liệu Air Quality cho thấy quan hệ tuyến tính rất mạnh với target (OLS/Ridge đạt R^2 khoảng 0.964), nên lợi ích kỳ vọng từ Kernel Regression không lớn so với chi phí triển khai. Bayesian Linear Regression cũng giữ được hệ số tuyến tính, dễ giải thích feature importance theo yêu cầu đề bài.

5 Phân tích các hàm chính

Mục này trình bày theo một khung thống nhất để người đọc dễ theo dõi: bối cảnh sử dụng, cơ sở lý thuyết, đầu vào, đầu ra, quy trình xử lý, và kiểm thử. Mọi hàm đều dùng biểu diễn ma trận bằng danh sách hai chiều để đồng nhất với các helper ma trận tự cài đặt.

5.1 Nhóm hàm OLS và kiểm định thống kê

5.1.1 `ols_fit`

- Bối cảnh sử dụng: Hàm lõi cho toàn bộ phần OLS, được tái sử dụng trong kiểm định thống kê, VIF và các phần lựa chọn biến.
- Cơ sở lý thuyết: Nghiệm đóng của OLS và ước lượng phương sai nhiễu $\hat{\sigma}^2 = RSS/(n-p-1)$.
- Đầu vào: X là ma trận $n \times (p+1)$ có cột chặn, y là vector cột $n \times 1$.
- Đầu ra: $\hat{\beta}$ dạng $(p+1) \times 1$ và $\hat{\sigma}^2$.
- Quy trình xử lý: Kiểm tra hợp lệ của ma trận, tính $X^T X$ và nghịch đảo, suy ra $\hat{\beta}$, sau đó tính $\hat{y}$, phần dư và RSS để suy ra $\hat{\sigma}^2$.
- Lưu ý: Nếu bậc tự do $n - (p+1)$ không dương, hàm báo lỗi để tránh ước lượng sai.

BÁO CÁO KIỂM THỬ: HỒI QUY OLS & SUY DIỄN THỐNG KÊ

Tổng quan dữ liệu: $n = 15$ mẫu quan sát, $p = 3$ biến số thực nghiệm.

[1] Đang khớp mô hình OLS (*ols_fit*)...

[2] Đang tính toán Ma trận hình mũ (*hat_matrix*)...


[3] Đang tính chỉ số đánh giá mô hình (*model_metrics*)...

[4] Đang suy diễn hệ số hồi quy (*coef_inference*)...

[5] Đang tính giá trị VIF (*vif*)...

5.1.2 `hat_matrix`

- Bối cảnh sử dụng: Phục vụ phân tích phần dư, tính đòn bẩy và khoảng Cook.
- Cơ sở lý thuyết: Ma trận chiếu $H = X(X^T X)^{-1} X^T$ với tính chất đối xứng và lũy đẳng.
- Đầu vào: Ma trận X đã có cột chặn.
- Đầu ra: Ma trận H kích thước $n \times n$.
- Quy trình xử lý: Tính $X^T X$, nghịch đảo và nhân lần lượt để tạo H .
- Lưu ý: Nếu $X^T X$ suy biến thì phép nghịch đảo sẽ lỗi, vì vậy dữ liệu phải không đa cộng tuyến hoàn hảo.
- Kiểm thử thực tế:
 - Thông số kiểm thử: Ma trận thiết kế X kích thước 15×4 (gồm cột chặn toàn 1).
 - Đầu ra kiểm thử thực tế: Ma trận chiếu chéo H kích thước 15×15 .
 - Ghi chú trực quan hóa: Hàm gốc chỉ trả về danh sách 2D số thực. Trong kiểm thử, kết quả được vẽ thành Bản đồ nhiệt ma trận Hat bên dưới để nhận diện các quan sát có leverage cao.



Hình 9: Bản đồ nhiệt ma trận Hat.

5.1.3 model_metrics

- Bối cảnh sử dụng: Tổng hợp các chỉ số đánh giá và kiểm định cho mô hình OLS.
- Cơ sở lý thuyết: R^2 , $\bar{R}^2$ và kiểm định F dựa trên RSS và TSS .
- Đầu vào: y , $\hat{y}$ và số biến giải thích p không tính cột chặn.
- Đầu ra: Từ điển gồm RSS , TSS , R^2 , $\bar{R}^2$, thống kê F và giá trị p.
- Quy trình xử lý: Tính trung bình y , suy ra RSS và TSS , sau đó tính các chỉ số và kiểm định F.
- Lưu ý: Nếu mẫu quá nhỏ làm mẫu số gần 0, hàm trả về F vô hạn và p bằng 0 để tránh lỗi số học.

Chỉ số	Giá trị
RSS	2.043295
TSS	905.127224
R_squared	0.997743
Adj_R_squared	0.997127
F_statistic	1620.572431
F_p_value	0.000000

Bảng 4: Các chỉ số đánh giá mô hình OLS.

5.1.4 `coef_inference`

- Bối cảnh sử dụng: Suy luận thống kê cho từng hệ số để phục vụ chọn biến và diễn giải mô hình.
- Cơ sở lý thuyết: Ma trận hiệp phương sai của $\hat{\beta}$ và kiểm định t theo phân phối Student.
- Đầu vào: X , y , $\hat{\beta}$ và $\hat{\sigma}^2$ từ `ols_fit`.
- Đầu ra: Danh sách sai số chuẩn, thống kê t, giá trị p và khoảng tin cậy 95%.
- Quy trình xử lý: Tính $(X^T X)^{-1}$, suy ra sai số chuẩn, thống kê t, sau đó lấy ngưỡng tới hạn 0.975 để lập khoảng tin cậy hai phía.
- Lưu ý: Diễn giải thống kê t dựa trên giả định phần dư có phân phối gần chuẩn.


Biến độc lập	Hệ số	Sai số	Giá trị t	Giá trị p	Khoảng tin cậy 95%
Hệ số chặn	4.7067	0.5219	9.0177	0.0000*	[3.558, 5.856]
Biến độc lập x1	3.6715	2.3585	1.5567	0.1478	[-1.519, 8.863]
Biến độc lập x2	-0.5355	1.1644	-0.4599	0.6545	[-3.098, 2.027]
Biến độc lập x3	0.1928	1.1777	0.1637	0.8729	[-2.399, 2.785]

Bảng 5: Bảng suy diễn hệ số hồi quy (*: có ý nghĩa thống kê ở mức 95%).

5.1.5 `vif`

- Bối cảnh sử dụng: Đo đa cộng tuyến để hỗ trợ loại biến không ổn định.
- Cơ sở lý thuyết: $VIF_j = 1/(1 - R_j^2)$ với R_j^2 từ hồi quy biến j theo các biến còn lại.
- Đầu vào: Ma trận X có cột chặn.

- Đầu ra: Danh sách VIF theo từng biến độc lập (bỏ qua cột chặn).
- Quy trình xử lý: Với mỗi biến, tạo bài toán hồi quy phụ, tính R^2 và suy ra VIF.
- Lưu ý: Nếu $1 - R^2$ rất nhỏ thì VIF tiến tới vô hạn, phản ánh đa cộng tuyến mạnh.
- Kiểm thử thực tế:
- Thông số kiểm thử: Ma trận thiết kế X kích thước 15×4 (gồm cột chặn).
- Đầu ra kiểm thử thực tế: Danh sách chứa $p = 3$ giá trị VIF của các biến độc lập.
- Ghi chú trực quan hóa: Hàm gốc trả về mảng số thực. Trong kiểm thử, VIF được trực quan hóa thành Biểu đồ cột phân màu cảnh báo mức độ đa cộng tuyến (Đỏ: Nghiêm trọng, Cam: Vừa phải, Xanh: An toàn).



Hình 10: Biểu đồ cột đánh giá đa cộng tuyến (VIF).

5.2 Nhóm hàm Ridge và k-fold CV

5.2.1 `ridge_fit`

- Bối cảnh sử dụng: Tính nghiệm Ridge để giảm phương sai khi các biến có tương quan cao.


- Cơ sở lý thuyết: $\hat{\beta} = (X^T X + \lambda I')^{-1} X^T y$, trong đó I' bỏ phạt hệ số chặn.
- Đầu vào: X , y và tham số phạt λ không âm.
- Đầu ra: $\hat{\beta}$ Ridge dạng $(p + 1) \times 1$.
- Quy trình xử lý: Tạo ma trận đơn vị, đặt phần tử chặn bằng 0, cộng với $X^T X$ rồi nghịch đảo để suy ra nghiệm.
- Lưu ý: Khi $\lambda = 0$, nghiệm Ridge trùng OLS.

Biến độc lập	Hệ số gốc	Ridge	Lasso
Hệ số chặn	5.000	5.006	5.005
Biến độc lập x1	3.500	3.214	3.210
Biến độc lập x2	-2.000	-2.090	-2.055
Biến độc lập x3 (nhiều)	0.000	0.053	0.000
Biến độc lập x4	1.200	1.141	1.098
Biến độc lập x5	-0.500	-0.595	-0.573

Bảng 6: So sánh hệ số hồi quy ($\lambda_{\text{ridge}} = 1.0$, $\lambda_{\text{lasso}} = 0.1$).

5.2.2 `plot_ridge_trace`

- Bối cảnh sử dụng: Minh họa sự co rút hệ số khi tăng λ để chọn vùng ổn định.
- Đầu vào: X , y , danh sách λ ; tùy chọn tên biến và số biến tối đa để hiển thị.
- Đầu ra: Danh sách quỹ đạo hệ số và biểu đồ đường theo $\log_{10}(\lambda)$.
- Quy trình xử lý: Với mỗi λ , gọi `ridge_fit`, gom hệ số, sau đó vẽ từng đường hệ số.
- Lưu ý: Nếu không truyền λ thì hàm sinh 100 giá trị theo thang lũy thừa từ 10^{-4} đến 10^4 .
- Kiểm thử thực tế:
- Thông số kiểm thử: Ma trận thiết kế X kích thước 50×6 , vector y kích thước 50×1 , và lưới 100 giá trị lambda từ 10^{-3} đến 10^3 .
- Đầu ra kiểm thử thực tế: Mảng vết hệ số `beta_traces` kích thước 100×6 .
- Ghi chú trực quan hóa: Đồ thị vết (Hình bên dưới) thể hiện sự co rút hệ số theo thang $\log_{10}(\lambda)$, được cấu hình thêm nhãn tiếng Việt trong kịch bản kiểm thử.




Hình 11: Biểu đồ đường vết hệ số Ridge (Ridge Trace).

5.2.3 `lasso_fit`

- Bối cảnh sử dụng: Tính nghiệm Lasso để tạo mô hình thưa khi các biến kém quan trọng cần bị loại hoàn toàn.
- Cơ sở lý thuyết: Tối thiểu hóa $\|y - X\beta\|^2 + \lambda\|\beta\|_1$ bằng Coordinate Descent với soft-threshold $S(z, \gamma) = \text{sign}(z) \cdot \max(|z| - \gamma, 0)$. Intercept không bị regularize.
- Đầu vào: X , y , tham số phạt $\lambda \geq 0$, số vòng lặp tối đa và ngưỡng hội tụ.
- Đầu ra: $\hat{\beta}$ Lasso dạng $(p + 1) \times 1$.
- Quy trình xử lý: Khởi tạo $\beta = 0$, tính trước tổng bình phương từng cột, lặp Coordinate Descent cập nhật từng β_j bằng soft-threshold cho đến khi hội tụ.
- Lưu ý: Khi λ đủ lớn, nhiều hệ số feature bằng đúng 0 (sparsity); khi $\lambda \rightarrow 0$, kết quả tiệm cận OLS.
- Kiểm thử thực tế:
- Thông số kiểm thử: Ma trận thiết kế X kích thước 50×6 , vector y kích thước 50×1 , $\lambda = 0.1$, $\text{max_iter}=1000$, $\text{tol}=1e-6$.

- Đầu ra kiểm thử thực tế: Vector hệ số Lasso $\hat{\beta}$ kích thước 6×1 .
- Ghi chú trực quan hóa: Hàm gốc chỉ tính toán số học. Trong kiểm thử, kết quả được vẽ thành biểu đồ Lasso Path bên dưới tương ứng với lưới 100 điểm lambda để quan sát hiệu ứng loại biến.




Hình 12: Biểu đồ đường vết hệ số Lasso (Lasso Path).

5.2.4 `kfold_cv`

- Bối cảnh sử dụng: Đánh giá độ ổn định của mô hình trên nhiều cách chia dữ liệu.
- Đầu vào: X , y , số k và hàm huấn luyện tùy chọn trả về $\hat{\beta}$.
- Đầu ra: MSE trung bình và danh sách MSE theo từng phần.
- Quy trình xử lý: Trộn chỉ số theo seed cố định, chia k phần, lặp qua từng phần làm kiểm tra, tính MSE và lấy trung bình.
- Lưu ý: Giá trị k phải trong khoảng $[2, n]$ để đảm bảo mỗi phần có dữ liệu.
- Kiểm thử thực tế:
- Thông số kiểm thử: Ma trận thiết kế X kích thước 50×6 , vector y kích thước 50×1 , số fold $k = 5$.

- Đầu ra kiểm thử thực tế: Lỗi đánh giá chéo trung bình `cv_mse` và mảng lỗi của từng fold `fold_mse`.
- Ghi chú trực quan hóa: Hàm gốc trả về số liệu tính toán. Trong kiểm thử, sai số của từng λ được vẽ thành đồ thị để hiển thị trực quan điểm tối ưu của Ridge và Lasso.




Hình 13: Biểu đồ tối ưu hóa Lambda bằng Cross-Validation.

5.3 Nhóm hàm phân tích phần dư

5.3.1 residual_plots

- Bối cảnh sử dụng: Kiểm tra giả định tuyến tính, chuẩn và đồng phương sai cho mô hình.
- Cơ sở lý thuyết: Dựa trên phần dư chuẩn hóa, đòn bẩy từ ma trận chiếu và khoảng Cook.
- Đầu vào: X , y , $\hat{\beta}$.
- Đầu ra: Một bộ hình gồm bốn biểu đồ chẩn đoán và cặp đối tượng hình, trực để tái sử dụng.
- Quy trình xử lý: Tính $\hat{y}$, phần dư, $\hat{\sigma}^2$, đòn bẩy, phần dư chuẩn hóa và khoảng Cook, sau đó vẽ bốn biểu đồ.
- Lưu ý: Ngưỡng khoảng Cook dùng $4/n$ để gợi ý điểm ảnh hưởng lớn.
- Kiểm thử thực tế:

- Thông số kiểm thử: Ma trận thiết kế X kích thước 50×6 , vector y kích thước 50×1 , vector hệ số OLS $\hat{\beta}$ kích thước 6×1 .
- Đầu ra kiểm thử thực tế: Đối tượng hình vẽ (**fig**) và các trục tọa độ (**axes**) của lưới 4 biểu đồ con.
- Ghi chú trực quan hóa: Trong kiểm thử, chúng tôi dịch toàn bộ nhãn đồ thị, chú giải và tiêu đề của 4 đồ thị con sang tiếng Việt để chẩn đoán tốt hơn các giả định OLS (xem Hình bên dưới).



Hình 14: Các biểu đồ chẩn đoán phần dư (Residual Diagnostics).

5.4 Nhóm hàm tiền xử lý dữ liệu

5.4.1 `DataPipeline.fit`

- Bối cảnh sử dụng: Học toàn bộ tham số tiền xử lý từ tập huấn luyện để tránh rò rỉ dữ liệu.
- Đầu vào: Bảng dữ liệu thô chưa tách target.

- Đầu ra: Đối tượng pipeline đã lưu cột bị loại, giá trị điền khuyết, biên cắt IQR, cấu trúc cột mã hóa và tham số chuẩn hóa.
- Quy trình xử lý: Trích xuất tháng, thứ trong tuần, giờ; loại cột thiếu quá ngưỡng; điền khuyết theo chiến lược; cắt ngọn outlier bằng IQR; mã hóa một nóng; lưu trung bình và độ lệch chuẩn cho chuẩn hóa.
- Lưu ý: Biến thời gian không bị cắt ngọn để giữ cấu trúc chu kỳ và dùng giá trị trung vị để tránh ảnh hưởng của nhiễu.
- Kiểm thử thực tế:
- Thông số kiểm thử: DataFrame thô huấn luyện kích thước 100×6 .
- Đầu ra kiểm thử thực tế: Đối tượng pipeline tự thân (`self`) đã lưu trữ các tham số tiền xử lý học được.
- Ghi chú trực quan hóa: Hàm gốc chỉ tính toán. Trong kiểm thử, kết quả học được biểu diễn dưới dạng bảng tham số chẩn đoán in ra console để dễ đối chiếu.

5.4.2 `DataPipeline.transform`

- Bối cảnh sử dụng: Áp dụng lại đúng các tham số đã học trên tập mới.
- Đầu vào: Bảng dữ liệu cần xử lý.
- Đầu ra: Bảng dữ liệu đã được biến đổi và chuẩn hóa theo cấu trúc của tập huấn luyện.
- Quy trình xử lý: Trích xuất thời gian, bỏ cột đã loại, điền khuyết theo giá trị đã học, cắt ngọn theo biên IQR, mã hóa một nóng, sau đó chuẩn hóa theo Z-score.
- Lưu ý: Có bước tái lập cột theo cấu trúc đã học để đảm bảo tập kiểm tra không thiếu cột.
- Kiểm thử thực tế:
- Thông số kiểm thử: DataFrame thô cần biến đổi và các tham số đã học từ `fit`.
- Đầu ra kiểm thử thực tế: DataFrame đã được biến đổi hoàn chỉnh (không còn NaN, outliers được winsorize, encode, chuẩn hóa Z-score).
- Ghi chú trực quan hóa: Hàm gốc chỉ trả về DataFrame số liệu. Trong kiểm thử, hiệu quả biến đổi được trực quan hóa bằng biểu đồ tỷ lệ khuyết thiếu và biểu đồ hộp phân phối ngoại lai trước và sau khi đi qua pipeline (xem Hình ở Mục 5.2).

Các tham số học được từ Pipeline (trên tập huấn luyện):

- Cột bị loại bỏ hoàn toàn (tỷ lệ khuyết > 50%): ['Biến_B_Khuyết_Nhiều']
- Giá trị điền khuyết đại diện:
 - Biến_A: 14.8208
 - Biến_C: 0.5059
 - Loại_Khu_Vực: Ngoại ô
- Giới hạn ngoại lai phát hiện (khoảng biên IQR Winsorization):
 - Biến_A: Dưới = 4.2348, Trên = 25.6238
 - Biến_C: Dưới = 0.2823, Trên = 0.7452
- Cột phân loại phát hiện: ['Loại_Khu_Vực']

5.5 Nhóm hàm Bayesian Linear Regression

5.5.1 `bayesian_linear_fit`

- Bối cảnh sử dụng: Bổ sung mô hình Bayes với prior Gaussian, vẫn giữ cấu trúc tuyến tính.
- Cơ sở lý thuyết: Hậu nghiệm Gaussian với $S_n = (S_0^{-1} + X^T X / \sigma^2)^{-1}$ và $m_n = S_n(S_0^{-1} m_0 + X^T y / \sigma^2)$.
- Đầu vào: X , y , tham số prior, và σ^2 có thể ước lượng từ OLS.
- Đầu ra: Posterior mean, posterior covariance, cùng các tham số prior và σ^2 .
- Quy trình xử lý: Kiểm tra kích thước, tạo prior precision theo phương sai, cộng với precision từ dữ liệu, nghịch đảo để lấy hậu nghiệm.
- Lưu ý: Intercept có phương sai prior rất lớn để gần như không bị điều chuẩn.
- Kiểm thử thực tế:
- Thông số kiểm thử: Ma trận thiết kế X kích thước 25×3 , vector y kích thước 25×1 , σ_{OLS}^2 , vector `prior_mean` bằng 0, phương sai `prior_variance` và `intercept_prior_variance` (10^{12}).

- Đầu ra kiểm thử thực tế: Kỳ vọng hậu nghiệm m_n kích thước 3×1 và ma trận hiệp phương sai posterior S_n kích thước 3×3 .
- Ghi chú trực quan hóa: Hàm gốc trả về phân phối hậu nghiệm số học. Trong kiểm thử, ma trận hiệp phương sai hậu nghiệm S_n được trực quan hóa thành bản đồ nhiệt (xem Hình bên dưới) để chẩn đoán độ biến động của các tham số.

5.5.2 `bayesian_predict`

- Bối cảnh sử dụng: Dự đoán theo kỳ vọng hậu nghiệm.
- Đầu vào: X và từ điển posterior từ `bayesian_linear_fit`.
- Đầu ra: Vector dự đoán $\hat{y}$ dạng $n \times 1$.
- Quy trình xử lý: Nhân ma trận X với $\mathbb{E}[\beta|X, y]$.

5.5.3 `credible_intervals`


- Bối cảnh sử dụng: Ước lượng khoảng tin cậy của hệ số theo hậu nghiệm.
- Đầu vào: Posterior và mức tin cậy α .
- Đầu ra: Danh sách khoảng tin cậy cho từng hệ số.
- Quy trình xử lý: Lấy phương sai trên đường chéo của ma trận hậu nghiệm, dùng hệ số z để tạo khoảng đối xứng.
- Lưu ý: Mặc định mức 95% dùng hệ số 1.96 để báo cáo gọn.
- Kiểm thử thực tế:
- Thông số kiểm thử: Từ điển phân phối hậu nghiệm `posterior`, mức tin cậy mặc định 0.95.
- Đầu ra kiểm thử thực tế: Danh sách khoảng tin cậy (biên dưới, biên trên) cho từng hệ số β_j .
- Ghi chú trực quan hóa: Hàm gốc trả về mảng số thực. Trong kiểm thử, kết quả được trực quan hóa thành biểu đồ khoảng tin cậy Bayesian 95% với thanh sai số màu tím và ngôi sao đỏ đánh dấu hệ số gốc để minh họa tính chính xác (xem Hình bên dưới).

Biến độc lập	Gốc	Hệ số OLS	Bayes (Prior yếu)	Bayes (Prior chuẩn)	Bayes (Prior mạnh)
Hệ số chặn (b_0)	3.000	3.177	3.177179	3.180790	3.210404
Biến x1 (b_1)	2.000	1.897	1.897247	1.838171	0.465670
Biến x2 (b_2)	-1.500	-1.120	-1.120425	-1.074257	-0.190493

Bảng 7: So sánh sự co rút hệ số hồi quy dưới các phương sai prior khác nhau.

Biến độc lập	Kỳ vọng Posterior	Khoảng tin cậy Bayesian 95%
Hệ số chặn (b_0)	3.1808	[2.8734, 3.4882]
Biến x1 (b_1)	1.8382	[1.5180, 2.1584]
Biến x2 (b_2)	-1.0743	[-1.4049, -0.7436]

Bảng 8: Khoảng tin cậy Bayesian 95% (Mô hình Prior chuẩn).



Hình 15: Kết quả phân tích hồi quy tuyến tính Bayes.

5.6 Nhóm hàm so sánh mô hình

5.6.1 `train_and_compare`

- Bối cảnh sử dụng: Quy trình tổng hợp từ tiền xử lý đến huấn luyện và so sánh 5 mô hình.
- Đầu vào: Đường dẫn dữ liệu, số k cho chia k phần, danh sách λ tùy chọn và cờ vẽ đồ thị.
- Đầu ra: Bảng chỉ số MAE/RMSE/ R^2 trên tập kiểm tra cho 5 mô hình, λ tối ưu của Ridge và Lasso, mô hình đã huấn luyện và dự đoán của từng mô hình.

- Quy trình xử lý: Đọc dữ liệu, tách target, chia tập 80/20, chạy pipeline, thêm cột chặn; chọn λ Ridge bằng k-fold CV; chọn λ Lasso bằng k-fold CV; huấn luyện OLS, OLS chọn biến, Ridge, Lasso và Bayesian Linear Regression; đánh giá MAE, RMSE, R^2 trên tập test.
- Lưu ý: Khi bật cờ `plot=True`, hàm vẽ đường CV-MSE theo λ cho cả Ridge và Lasso, cùng biểu đồ Ridge Trace.
- Kiểm thử thực tế:
- Thông số kiểm thử: Đường dẫn dữ liệu `AirQuality.csv`, số fold $k = 5$, mảng lambda điều chuẩn, đặt `plot=False` trong kiểm thử để vẽ tùy biến.
- Đầu ra kiểm thử thực tế: Từ điển kết quả chứa lambda tối ưu, bảng metrics (MAE, RMSE, R^2), nhật ký loại biến, mô hình đã khớp và dự đoán.
- Ghi chú trực quan hóa: Trong kiểm thử, dữ liệu trả về được dùng để vẽ biểu đồ so sánh hiệu năng 5 mô hình và biểu đồ phân tán Thực tế vs Dự báo (xem Hình ở Mục 5.3).

Tên mô hình hồi quy	MAE	RMSE	R-squared
OLS (Đầy đủ biến)	0.88998	1.44609	0.96361
OLS (Chọn biến)	1.42849	2.07262	0.92524
Hồi quy Ridge ($\lambda = 0.1$)	0.88996	1.44608	0.96361
Hồi quy Lasso ($\lambda = 0.0001$)	0.88986	1.44602	0.96361
Hồi quy tuyến tính Bayes	0.88998	1.44609	0.96361

Bảng 9: Chỉ số đánh giá hiệu năng mô hình (Trên tập kiểm thử Test Set).

6 Kết luận

Kết quả thực nghiệm cho thấy mô hình tuyến tính mô tả tốt dữ liệu Air Quality với $R^2 \approx 0.964$. Ridge và Lasso đạt MAE/RMSE tốt nhất nhưng chênh lệch rất nhỏ so với OLS và Bayesian Linear Regression – điều này hợp lý vì các biến cảm biến có quan hệ tuyến tính rất mạnh với target `C6H6(GT)`. OLS chọn biến giúp mô hình gọn hơn nhưng làm giảm hiệu suất đáng kể do loại bỏ các biến có tín hiệu dự báo mạnh (đặc biệt `PT08.S2(NMHC)`).

Các điểm đạt được:

- Cài đặt đầy đủ các thuật toán yêu cầu từ công thức toán học (OLS, Ridge, Lasso, k-fold CV, VIF, Bayesian LR) và có kiểm chứng bằng unit test.

- Pipeline tiền xử lý đảm bảo fit/transform đúng chuẩn, tránh data leakage.
- So sánh 5 mô hình (OLS, OLS chọn biến, Ridge, Lasso, Bayesian LR), phân tích phần dư và feature importance đáp ứng tiêu chí đề bài.
- Lasso bổ sung khả năng tạo mô hình thưa so với Ridge, mở rộng bộ công cụ regularization của nhóm.

Hạn chế và hướng mở rộng:

- Có thể thử thêm biến tương tác hoặc biến phi tuyến để kiểm tra cải thiện hiệu suất.
- Đánh giá độ ổn định của chọn biến qua nhiều lần split hoặc k-fold trên toàn bộ pipeline.
- Lasso với dữ liệu chuẩn hóa có thể chọn tự động tập biến quan trọng – đây là hướng mở rộng thú vị khi so sánh với OLS chọn biến thủ công.

Tài liệu tham khảo

1. Gilbert Strang. *Introduction to Linear Algebra*, 6th ed. Wellesley-Cambridge Press, 2023.
2. Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani. *An Introduction to Statistical Learning*, 2nd ed. Springer, 2021. <https://www.statlearning.com>
3. Trevor Hastie, Robert Tibshirani, Jerome Friedman. *The Elements of Statistical Learning*, 2nd ed. Springer, 2009. <https://hastie.su.domains/ElemStatLearn/>
4. Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
5. Kevin P. Murphy. *Probabilistic Machine Learning: An Introduction*. MIT Press, 2022. <https://probml.github.io/pml-book/book1.html>
6. Jake VanderPlas. *Python Data Science Handbook*. O'Reilly, 2016. <https://jakevdp.github.io/PythonDataScienceHandbook/>
7. Wes McKinney. *Python for Data Analysis*, 3rd ed. O'Reilly, 2022.



Phụ lục A: Bảng số liệu và kết quả bổ sung

A1. Thống kê mô tả các biến số

	count	mean	std	min	25%	50%	75%	max
CO(GT)	7344.000000	2.129700	1.436500	0.100000	1.100000	1.800000	2.800000	11.900000
PT08.S1(CO)	8991.000000	1099.833200	217.080000	647.000000	937.000000	1063.000000	1231.000000	2040.000000
NMHC(GT)	887.000000	218.607700	206.615100	7.000000	66.000000	145.000000	297.000000	1189.000000
PT08.S2(NMHC)	8991.000000	939.153400	266.831400	383.000000	734.500000	909.000000	1116.000000	2214.000000
NOx(GT)	7396.000000	242.189300	206.312000	2.000000	97.000000	178.000000	321.000000	1479.000000
PT08.S3(NOx)	8991.000000	835.493600	256.817300	322.000000	658.000000	806.000000	969.500000	2683.000000
NO2(GT)	7393.000000	112.145100	47.629100	2.000000	77.000000	109.000000	140.000000	333.000000
PT08.S4(NO2)	8991.000000	1456.264600	346.206800	551.000000	1227.000000	1463.000000	1674.000000	2775.000000
PT08.S5(O3)	8991.000000	1022.906100	398.484300	221.000000	731.500000	963.000000	1273.500000	2523.000000
T	8991.000000	18.317800	8.832100	-1.900000	11.800000	17.800000	24.400000	44.600000
RH	8991.000000	49.234200	17.316900	9.200000	35.800000	49.600000	62.500000	88.700000
AH	8991.000000	1.025500	0.403800	0.184700	0.736800	0.995400	1.313700	2.231000
C6H6(GT)	8991.000000	10.083100	7.449800	0.100000	4.400000	8.200000	14.000000	63.700000

Bảng 10: Thống kê mô tả các biến số trong Air Quality (sau khi loại dòng thiếu target).

A2. Ma trận tương quan (các biến quan trọng và target)

	PT08.S2(NMHC)	PT08.S3(NOx)	T	AH	PT08.S1(CO)	PT08.S4(NO2)	RH	Hour	NOx(GT)	PT08.S5(O3)	C6H6(GT)
PT08.S2(NMHC)	1.000000	-0.826000	0.239000	0.185000	0.894000	0.773000	-0.086000	0.397000	0.644000	0.881000	0.976000
PT08.S3(NOx)	-0.826000	1.000000	-0.136000	-0.229000	-0.807000	-0.550000	-0.066000	-0.338000	-0.675000	-0.827000	-0.766000
T	0.239000	-0.136000	1.000000	0.658000	0.046000	0.566000	-0.579000	0.204000	-0.267000	-0.031000	0.193000
AH	0.185000	-0.229000	0.658000	1.000000	0.132000	0.634000	0.166000	-0.023000	-0.161000	0.071000	0.167000
PT08.S1(CO)	0.894000	-0.807000	0.046000	0.132000	1.000000	0.674000	0.118000	0.335000	0.666000	0.902000	0.879000
PT08.S4(NO2)	0.773000	-0.550000	0.566000	0.634000	0.674000	1.000000	-0.031000	0.223000	0.188000	0.589000	0.757000
RH	-0.086000	-0.066000	-0.579000	0.166000	0.118000	-0.031000	1.000000	-0.296000	0.198000	0.134000	-0.053000
Hour	0.397000	-0.338000	0.204000	-0.023000	0.335000	0.223000	-0.296000	1.000000	0.244000	0.250000	0.351000
NOx(GT)	0.644000	-0.675000	-0.267000	-0.161000	0.666000	0.188000	0.198000	0.244000	1.000000	0.741000	0.632000
PT08.S5(O3)	0.881000	-0.827000	-0.031000	0.071000	0.902000	0.589000	0.134000	0.250000	0.741000	1.000000	0.862000
C6H6(GT)	0.976000	-0.766000	0.193000	0.167000	0.879000	0.757000	-0.053000	0.351000	0.632000	0.862000	1.000000

Bảng 11: Ma trận tương quan giữa các biến quan trọng (theo hệ số OLS) và target.

A3. Kết quả chọn lambda bằng k-fold CV

lambda	log10_lambda	cv_mse
0.100000	-1.000000	1.993500
0.046416	-1.333333	1.993500
0.021544	-1.666667	1.993500
0.010000	-2.000000	1.993500
0.004642	-2.333333	1.993501

Bảng 12: Top 5 lambda theo CV-MSE (k=5).



A4. Top hệ số OLS sau chuẩn hóa

Feature	Coefficient
PT08.S2(NMHC)	8.523142
PT08.S3(NO _x)	1.305243
T	-0.938744
AH	0.859431
PT08.S1(CO)	0.513167
PT08.S4(NO ₂)	-0.438952
RH	-0.428300
Hour	-0.240929
NO _x (GT)	0.176963
PT08.S5(O ₃)	-0.165408

Bảng 13: Top 10 hệ số OLS theo trị tuyệt đối (dữ liệu chuẩn hóa).

Phụ lục B: GitHub Repository

Mã nguồn của dự án được lưu trữ tại địa chỉ sau: https://github.com/TNTruong196/Prj2_TUOTK_N1.git

Hết.